

Mini Projet : Reconnaissance d'Activité Humaine à partir de Smartphones

Dataset : Human Activity Recognition Using Smartphones (HAR)

Réalisé par :

Hamdane Salsabil
Benaissa Roumeissa

Encadré par :
Dr S.Zerabi

24 janvier 2026

Table des matières

Introduction	2
1 Présentation du Dataset	3
1.1 Source et caractéristiques	3
2 Analyse Exploratoire des Données (EDA)	4
2.1 Description des features du dataset	4
2.2 Type de données pour chaque feature	4
2.3 Valeurs manquantes (Missing Values)	4
2.4 Distribution des activités dans le jeu d'entraînement	5
2.5 Classification des activités selon le type	5
2.6 valeurs aberrantes (outliers)	6
2.7 Analyse de la distribution des features et traitement des non-normalités	7
2.8 Corrélation :	7
2.8.1 Matrice de Corrélation entre les Features (Features vs Features)	7
2.8.2 Corrélation entre chaque Feature et l'Activity (Feature vs Activity)	9
3 Prétraitement des données	10
3.1 Nettoyage des données	10
3.1.1 Les valeurs manquantes (missing values)	10
3.1.2 Les valeurs aberrantes (missing values)	10
3.1.3 L'encodage des labels	10
3.2 Normalisation	11
3.3 PCA	11
4 Machine Learning Supervisé	12
4.1 Validation croisée (Cross-Validation)	12
4.1.1 Principe	12
4.1.2 Application aux modèles supervisés	12
4.1.3 Méthode utilisée	12
4.2 Algorithmes appliqués	13
4.3 Évaluation des modèles	13
4.3.1 Comparaison des performances des modèles de classification	13
5 Machine Learning Non Supervisé	15
5.1 Algorithmes appliqués	15
5.2 Évaluation des modèles	15
5.2.1 Analyse comparative des méthodes de clustering	16

Introduction

Le dataset ‘Human Activity Recognition Using Smartphones (HAR) Son objectif est reconnaître les activités quotidiennes des humains en utilisant les données collectées à partir de capteurs tels que les smartphones et les montres intelligentes. Ce domaine permet d’analyser le comportement humain. Dans ce projet, notre objectif est de réaliser une analyse exploratoire des données (Exploratory Data Analysis, EDA) sur le dataset HAR afin de comprendre la distribution des activités et des features, et de détecter d’éventuels problèmes dans les données tels que les valeurs manquantes ou les valeurs aberrantes (outliers). Ensuite, nous procéderons au prétraitement des données (Data Preprocessing), incluant la transformation des données, l’organisation des valeurs, et éventuellement la sélection des features importantes. Nous appliquerons ensuite des modèles de Machine Learning, à la fois supervisés tels que (l’arbre de décision, la forêt aléatoireect) , et non supervisés comme le clustering (kNN, DBSCAN ect) pour analyser les activités sans labels. Enfin, nous comparerons la performance des différents modèles à l’aide de métriques appropriées afin de déterminer les modèles les plus efficaces pour analyser ce type de données et prédire les activités avec une grande précision.

Chapitre 1

Présentation du Dataset

1.1 Source et caractéristiques

- Dataset : HAR
- Source : <https://archive.ics.uci.edu/dataset/24/human+activity+recognition+using+smartphones>
- Nombre d'instances : 10 299 échantillons (7 352 Training set, 2 947 Test set)
- Nombre d'attributs : 561 + 1
- Nombre de classes : 6

Chapitre 2

Analyse Exploratoire des Données (EDA)

Après avoir chargé le dataset *Human Activity Recognition (HAR)*, nous avons effectué une analyse exploratoire des données afin de comprendre la nature des données et la distribution des activités :

2.1 Description des features du dataset

Ces features sont calculées à partir des données issues des capteurs inertiels intégrés aux smartphones, et proviennent principalement des sources suivantes :

- Accélération gravitationnelle selon les axes x , y et z
- Accélération du corps (*Body Acceleration*) selon les axes x , y et z
- Données du gyroscope du corps (*Body Gyroscope*) selon les axes x , y et z

Les features incluent des statistiques telles que la moyenne (*mean*), l'écart-type (*std*), la déviation moyenne absolue (*mad*), le maximum (*max*), ainsi que d'autres mesures avancées comme la *skewness* et la *kurtosis*. Ces caractéristiques sont calculées aussi bien dans le domaine temporel (*time domain*) que dans le domaine fréquentiel (*frequency domain*).

En plus des features statistiques classiques, le dataset contient également des caractéristiques angulaires telles que :

- `angle(tBodyAccMean, gravity)`
- `angle(tBodyGyroMean, gravityMean)`
- `angle(X, gravityMean)`

Ces angles permettent de capturer la relation spatiale entre les signaux du corps et le vecteur de gravité, ce qui améliore la capacité du modèle à distinguer les différentes activités.

Enfin, la colonne `Activity` représente le label de classe associé à chaque échantillon, portant ainsi le nombre total de colonnes du dataset à **562** (561 features + 1 label).

2.2 Type de données pour chaque feature

- Le nombre de features de type `float64` est de 561, représentant les valeurs numériques collectées par les capteurs de mouvement (*Accelerometer* et *Gyroscope*).
- Une seule colonne est de type `object`, correspondant à la colonne `Activity` qui représente le nom de l'activité.

2.3 Valeurs manquantes (Missing Values)

Aucune valeur manquante n'a été détectée dans les colonnes, ce qui facilite le prétraitement (*Preprocessing*) des données.

2.4 Distribution des activités dans le jeu d'entraînement

- **LAYING** : 1407
- **STANDING** : 1374
- **SITTING** : 1286
- **WALKING** : 1226
- **WALKING_UPSTAIRS** : 1073
- **WALKING_DOWNSTAIRS** : 986




FIGURE 2.1 – Différentes activités humaines et leur nombre dans l'ensemble de données d'entraînement

On remarque que certaines activités dynamiques (*WALKING*, *WALKING_UPSTAIRS*, *WALKING_DOWNSTAIRS*) ont un nombre d'exemples inférieur par rapport aux activités statiques (*SITTING*, *STANDING*, *LAYING*).

2.5 Classification des activités selon le type

- **Activités statiques (Static Activities)** : *SITTING*, *STANDING*, *LAYING*
- **Activités dynamiques (Dynamic Activities)** : *WALKING*, *WALKING_UPSTAIRS*, *WALKING_DOWNSTAIRS*




FIGURE 2.2 – Enter Caption

La feature `tBodyAccMag-mean()` a été choisie pour représenter l'intensité du mouvement, car elle combine l'accélération du corps dans toutes les directions et fournit une mesure uniforme de la force de l'activité. L'analyse exploratoire montre que cette feature permet de distinguer clairement les activités statiques des activités dynamiques, ce qui la rend adaptée à l'utilisation dans les modèles de reconnaissance d'activités humaines.

2.6 valeurs aberrantes (outliers)

Nous avons analysé les *outliers* sur 10 features principales du dataset en utilisant des *box-plots*. Les graphiques montrent la présence de certaines valeurs aberrantes (*outliers*) situées en dehors du premier et du troisième quartile. Ces valeurs pourraient affecter la stabilité du modèle si elles ne sont pas traitées.




FIGURE 2.3 – Enter Caption

2.7 Analyse de la distribution des features et traitement des non-normalités

Après avoir tracé les courbes de densité (*Density curves*) et les histogrammes (*Histograms*) de dix features aléatoires du dataset, nous avons observé que la plupart des features ne suivent pas une distribution normale (*Non-Normal Distribution*), avec une grande variabilité des valeurs et certaines features présentant de longues queues.

Cela indique que certains modèles qui supposent une distribution normale des données (comme la régression logistique, *Logistic Regression*) peuvent nécessiter une correction de la distribution avant l'entraînement, par exemple en utilisant des techniques de *scaling* (*StandardScaler* ou *MinMaxScaler*) ou de *transformation* (comme la *Log Transformation*), afin d'assurer la stabilité du modèle et d'améliorer ses performances.




FIGURE 2.4 – Enter Caption

2.8 Corrélation :

2.8.1 Matrice de Corrélation entre les Features (Features vs Features)

Il s'agit d'une *heatmap* montrant la force de la relation entre chaque paire de features.

Couleurs :

- Rouge foncé → forte corrélation positive (les features évoluent dans le même sens)
- Bleu foncé → forte corrélation négative (les features évoluent dans des directions opposées)
- Couleurs claires → corrélation faible ou nulle

Les valeurs numériques dans chaque case représentent la *Pearson Correlation* entre les features.

Objectif de cette analyse :

- Identifier si certaines features sont très corrélées → possibilité de supprimer certaines pour réduire la redondance (*redundancy*)
- Comprendre les relations internes des données avant l'entraînement du modèle

La *heatmap* montre que certaines features sont fortement corrélées entre elles, ce qui suggère qu'il est possible de réduire le nombre de features sans perdre d'informations importantes, contribuant ainsi à diminuer la complexité et à améliorer la performance des modèles.




FIGURE 2.5 – Enter Caption

2.8.2 Corrélation entre chaque Feature et l'Activity (Feature vs Activity)

Il s'agit d'un graphique montrant la valeur de la *Pearson Correlation* de chaque feature avec la colonne `Activity_num`.

Barres :

- Barre à droite de zéro → corrélation positive : plus la feature augmente, plus la probabilité d'une activité dynamique augmente.
- Barre à gauche de zéro → corrélation négative : augmentation de la feature liée aux activités statiques.

Objectif de cette analyse :

- Identifier quelles features sont très importantes pour la reconnaissance des activités humaines.
- Les features avec une corrélation élevée, positive ou négative, sont particulièrement utiles pour l'entraînement du modèle car elles permettent de distinguer les activités statiques des activités dynamiques.

Le graphique montre que certaines features présentent une forte corrélation avec les activités, ce qui les rend très utiles pour la classification des activités humaines, tandis que les features avec une faible corrélation peuvent avoir un impact moindre.




FIGURE 2.6 – Enter Caption

Chapitre 3

Prétraitement des données

Après l'analyse exploratoire des données (EDA), une phase de prétraitement a été réalisée afin de préparer les données pour l'entraînement des modèles de classification. Cette phase comprend le nettoyage des données, la normalisation et la réduction de dimension par PCA.

3.1 Nettoyage des données

3.1.1 Les valeurs manquantes (missing values)

La vérification des valeurs manquantes réalisée dans la phase EDA a montré l'absence totale de données manquantes dans le dataset HAR, ce qui permet de conserver l'ensemble des observations sans appliquer de méthodes d'imputation ou de suppression. Décrire les étapes de suppression ou imputation des valeurs manquantes.

3.1.2 Les valeurs aberrantes (missing values)

L'analyse des valeurs aberrantes (outliers) a été effectuée afin d'identifier les observations présentant des écarts extrêmes par rapport à la majorité des données. Ces valeurs ont été détectées à l'aide de boxplots sur plusieurs features du dataset HAR. Dans le contexte de ce dataset, les outliers reflètent souvent des variations réelles des signaux provenant des capteurs (accéléromètre et gyroscope) et ne doivent pas être supprimés, car elles représentent des mouvements humains authentiques. Pour limiter leur impact sur les modèles sensibles aux échelles et aux valeurs extrêmes, une étape de normalisation a été appliquée lors du prétraitement, garantissant ainsi que ces valeurs aberrantes n'affectent pas la stabilité et la performance des modèles de classification.

3.1.3 L'encodage des labels

constitue une étape essentielle dans le prétraitement des données de classification. Dans le dataset HAR, la colonne Activity contient les noms des activités humaines sous forme de texte (par exemple, "WALKING", "SITTING", "LAYING"). Comme la plupart des algorithmes d'apprentissage automatique ne peuvent traiter que des valeurs numériques, un LabelEncoder a été utilisé pour convertir chaque activité en un nombre entier unique. Cette transformation permet de représenter chaque catégorie de manière numérique tout en conservant la correspondance entre le nom de l'activité et son code associé. Par exemple, "LAYING" est codée par 0, "SITTING" par 1, et ainsi de suite. Cet encodage facilite l'entraînement des modèles de classification et permet de gérer efficacement les labels lors de la prédiction.

3.2 Normalisation

La normalisation des données est une étape essentielle du prétraitement qui consiste à mettre toutes les features numériques sur une même échelle. Dans le dataset HAR, les valeurs des capteurs varient fortement selon le type de mesure (accelerometer, gyroscope), ce qui pourrait entraîner la domination de certaines variables lors de l'entraînement des modèles. Pour pallier ce problème, une normalisation a été appliquée à l'aide d'un MinMaxScaler, transformant toutes les valeurs dans l'intervalle $[0,1]$. Cette opération assure que chaque feature contribue de manière équitable, réduit l'impact des valeurs extrêmes et prépare les données pour les étapes suivantes, telles que la réduction de dimension par PCA et l'entraînement des modèles de classification.

3.3 PCA

La réduction de dimension a été effectuée à l'aide de l'Analyse en Composantes Principales (PCA) afin de diminuer le nombre de features tout en conservant l'essentiel de l'information contenue dans les données. Dans le dataset HAR, le nombre initial de features est très élevé (561), ce qui peut augmenter la complexité des modèles et favoriser le surapprentissage (overfitting). L'application du PCA a permis de projeter les données dans un espace de dimension réduite, en conservant les composantes principales qui expliquent la majorité de la variance. Cette étape réduit la redondance entre les features fortement corrélées, améliore la performance et la stabilité des modèles de classification, et facilite également la visualisation des données.

Chapitre 4

Machine Learning Supervisé

4.1 Validation croisée (Cross-Validation)

La validation croisée est une technique essentielle pour évaluer la capacité de généralisation d'un modèle de machine learning. Elle permet de tester le modèle sur des données qu'il n'a pas vues pendant l'entraînement, ce qui aide à réduire le risque de surapprentissage (*overfitting*) et fournit une estimation plus fiable de la performance réelle du modèle.

4.1.1 Principe

Le jeu de données est divisé en k sous-ensembles appelés plis (*folds*).

- À chaque itération, le modèle est entraîné sur $k - 1$ plis et testé sur le pli restant.
- Cette procédure est répétée k fois, en changeant le pli utilisé pour la validation à chaque fois.
- Les performances du modèle sont calculées à chaque itération et la moyenne des scores est utilisée comme estimation finale.

4.1.2 Application aux modèles supervisés

Dans notre étude, la validation croisée a été appliquée à quatre modèles supervisés :

- KNN (*K-Nearest Neighbors*)
- Arbre de décision (*Decision Tree*)
- Random Forest
- ANN (*Artificial Neural Network*)

4.1.3 Méthode utilisée

- La *k-fold cross-validation* a été utilisée avec $k = 5$ et $k = 10$.
- `shuffle=True` activé pour mélanger les données avant de les diviser en plis, afin de garantir une répartition équilibrée des classes dans chaque pli.
- Paramètres principaux :
 - `n_splits` : nombre de plis (k), choisi ici 5 ou 10.
 - `shuffle=True` : mélange aléatoire des données avant division.
 - `random_state` : fixe la reproductibilité des résultats.

4.2 Algorithmes appliqués

Algorithme	Description	Paramètres et remarques
K-Nearest Neighbors (KNN)	Méthode de classification supervisée basée sur le principe de similarité. Pour classer une nouvelle observation, l'algorithme recherche les k voisins les plus proches dans l'espace des caractéristiques et assigne la classe la plus fréquente.	n_neighbors = 5 : nombre de voisins pris en compte metric = Minkowski (Euclidienne) : mesure de distance weights = uniform : importance égale pour tous les voisins Remarque : sensible à l'échelle des variables, normalisation appliquée.
Arbre de Décision (Decision Tree)	Méthode supervisée reposant sur une structure arborescente composée de nœuds de décision, branches et feuilles. Chaque nœud interne représente un test sur une caractéristique et chaque feuille représente une classe finale.	criterion = gini : qualité des séparations random_state = 42 : reproductibilité
Random Forest	Méthode supervisée basée sur un ensemble d'arbres de décision (ensemble learning). Combine les prédictions de plusieurs arbres pour améliorer la performance et réduire le sur-apprentissage.	n_estimators = 100 : nombre d'arbres criterion = gini : qualité des séparations random_state = 42 : reproductibilité
Artificial Neural Network (ANN)	Modèle supervisé inspiré du cerveau humain, constitué de couches de neurones interconnectés (entrée, cachées, sortie). Chaque neurone applique une transformation non linéaire pour capturer les relations complexes entre les caractéristiques.	hidden_layer_sizes = (50,50) : deux couches cachées de 50 neurones chacune max_iter = 500 : nombre maximal d'itérations random_state = 42 : reproductibilité

TABLE 4.1 – Résumé des algorithmes KNN, Decision Tree, Random Forest et ANN avec leurs paramètres et remarques

4.3 Évaluation des modèles

- Précision, rappel, accuracy, F1-score
- Matrice de confusion
- Courbe ROC

4.3.1 Comparaison des performances des modèles de classification

Afin d'évaluer les performances des quatre modèles supervisés appliqués au jeu de données HAR, qui ont été comparés : *K-Nearest Neighbors (KNN)*, *Decision Tree*, *Random Forest* et *Artificial Neural Network (ANN)*. Les résultats obtenus montrent que le modèle ANN atteint les meilleures performances globales, avec une accuracy de 0.596, une précision de 0.600, un rappel de 0.604 et un score F1 de 0.589. Ces résultats indiquent une meilleure capacité du réseau de neurones à capturer la complexité et la non-linéarité des données d'activités humaines.

Le modèle Random Forest se classe en deuxième position avec une accuracy de 0.573 et un score F1 de 0.581, offrant un bon compromis entre performance et robustesse grâce à l'agrégation

de plusieurs arbres de décision. En revanche, l'algorithme KNN présente des performances intermédiaires (accuracy de 0.558), bien qu'il bénéficie d'un temps d'entraînement très réduit, ce qui le rend adapté aux applications nécessitant une exécution rapide. Le modèle Decision Tree affiche les performances les plus faibles, avec une accuracy de 0.531, ce qui peut s'expliquer par sa sensibilité au bruit et au sur-apprentissage.

Concernant le temps d'entraînement, KNN et Decision Tree sont les plus rapides, tandis que Random Forest et ANN nécessitent un temps de calcul plus important, respectivement de 10.13 secondes et 20.63 secondes. L'analyse des matrices de confusion révèle également une difficulté commune à tous les modèles à distinguer certaines activités aux caractéristiques similaires, notamment les activités dynamiques. En conclusion, le modèle ANN s'avère le plus performant pour cette tâche de classification, au prix d'un temps d'entraînement plus élevé, tandis que Random Forest représente une alternative équilibrée entre précision et coût computationnel.




FIGURE 4.1 – Comparaison Globale

Chapitre 5

Machine Learning Non Supervisé

5.1 Algorithmes appliqués

Algorithme	Description	Paramètres et résultats
K-Means	Algorithme de clustering non supervisé qui regroupe les données en K clusters de manière à ce que les observations dans le même cluster soient les plus similaires possibles et différentes des autres clusters. La similarité est mesurée par la distance euclidienne entre points et centroïdes.	n_clusters = 6 : six clusters correspondant aux activités random_state = 46 : reproductibilité Données normalisées (X_scaled) Silhouette Score = 0.125 : structure identifiée mais séparation limitée entre clusters
Agglomerative Clustering	Méthode de regroupement hiérarchique. Chaque point commence comme cluster indépendant puis les clusters les plus proches sont fusionnés jusqu'au nombre souhaité. Permet de comprendre la structure interne et relations entre données.	n_clusters = 6 : six activités linkage = ward : minimise la variance intra-cluster Silhouette Score = 0.106 : clusters cohérents mais quelques chevauchements Visualisations : 1. Scatter plot 2D via PCA 2. Dendrogramme (arbre hiérarchique)
DBSCAN	Méthode de clustering basée sur la densité. Regroupe les points proches et considère les points isolés comme bruit (outliers). Pas besoin de nombre de clusters au préalable.	eps = 3 min_samples = 5 Résultat : 2 clusters détectés avec 42 outliers Silhouette Score = 0.335 : séparation correcte mais insuffisante pour 6 activités

TABLE 5.1 – Résumé des algorithmes de clustering K-Means, Agglomerative Clustering et DBSCAN avec leurs paramètres et résultats

5.2 Évaluation des modèles

- Silhouette
- Davies-Bouldin
- Adjusted Rand Index

5.2.1 Analyse comparative des méthodes de clustering

L'étude comparative des méthodes de clustering met en évidence des comportements distincts selon la nature de chaque algorithme. L'algorithme K-Means parvient à identifier une structure globale dans les données, mais il reste limité par sa sensibilité à l'initialisation et par sa difficulté à séparer des groupes présentant des caractéristiques proches.

Le clustering hiérarchique agglomératif montre une meilleure cohérence dans la correspondance entre les clusters obtenus et les classes réelles, ce qui reflète sa capacité à exploiter la structure interne des données. Toutefois, la séparation entre les groupes demeure partielle, indiquant un certain chevauchement entre certaines activités.

En revanche, l'algorithme DBSCAN se distingue par une meilleure séparation des groupes détectés, grâce à son approche basée sur la densité. Cependant, il n'est pas en mesure de refléter fidèlement la structure réelle des données, en raison de la présence de nombreux points considérés comme du bruit et de la fusion de plusieurs activités au sein de mêmes clusters.

En conclusion, les résultats montrent qu'aucune méthode de clustering ne permet une séparation parfaite des activités. Les algorithmes basés sur la partition et la hiérarchie offrent une meilleure correspondance avec les classes réelles, tandis que les approches basées sur la densité sont plus adaptées à la détection de structures locales, mais restent limitées dans ce contexte.

Conclusion

À travers cette étude, plusieurs méthodes de classification supervisée et de clustering non supervisé ont été appliquées afin d'analyser les données d'activités humaines. Les résultats obtenus montrent que les approches supervisées offrent globalement de meilleures performances, grâce à l'exploitation des labels lors de l'apprentissage, ce qui permet une meilleure discrimination entre les différentes activités.

En revanche, les méthodes de clustering, bien qu'utiles pour l'exploration des données et la compréhension de leur structure interne, présentent des limites dans la séparation des activités, principalement en raison du chevauchement important entre certaines classes. Chaque algorithme de clustering a mis en évidence des aspects différents des données, sans toutefois parvenir à une partition parfaitement représentative de la structure réelle.

En conclusion, cette étude souligne l'importance du choix de l'algorithme en fonction de l'objectif visé. Les méthodes supervisées sont plus adaptées lorsque les labels sont disponibles et que la précision est requise, tandis que les approches non supervisées restent pertinentes pour l'analyse exploratoire et la découverte de structures cachées dans les données.